선형 회귀(Linear Regression) 모델 구현하기

- 플레이스 홀더를 선언 후, 그래프 실행시에 데이터를 입력받아, 연산 수행

2-1. 라이브러리 불러오기 및 데이터 지정

In [4]:

```
from IPython.display import display, Image
```

In [5]:

```
display(Image(filename='../img/TF_Regression01.png'))
```

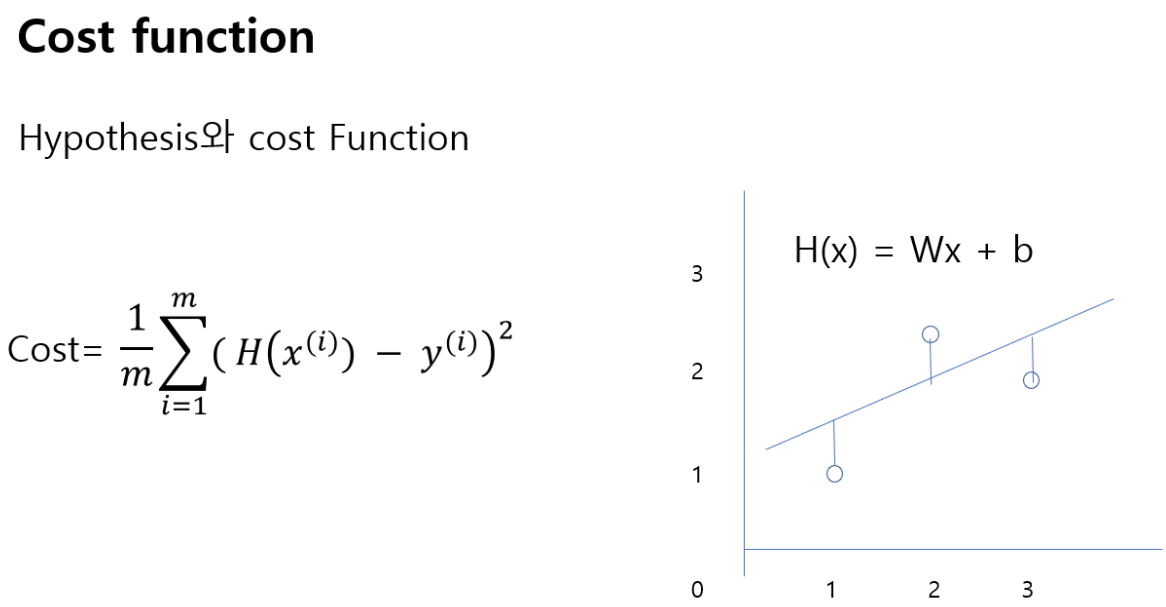

In [6]:

```
import tensorflow as tf
```

학습을 위한 데이터 지정

In [7]:

```
x_data = [1,2,3,4,5]
y_data = [10,20,30,40,50]
```

2.2 W와 b를 각각 -1~1 사이의 균등분포(uniform distributiion)를 가진 무작위값으로 초기화수행

- 가중치(Weight)와 Bias를 임의의 값(-1 ~ 1)으로 초기화
- tf.random_uniform(shape, minval=0, maxval=None, dtype=tf.float32, seed=None, name=None) : 균등 분포로 부터 난수값 발생.

In [8]:

```
W = tf.Variable(tf.random_uniform( [1], -1.0, 1.0) )
b = tf.Variable(tf.random_uniform( [1], -1.0, 1.0) )
print(W)
print(b)
```

```
<tf.Variable 'Variable:0' shape=(1,) dtype=float32_ref>
<tf.Variable 'Variable_1:0' shape=(1,) dtype=float32_ref>
```

2.3 플레이스 홀더(placeholder) 설정(이름 지정 - name)

- 플레이스 홀더는 나중에 데이터를 할당되는 심플한 변수이다.
- 데이터 없이도 텐서 그래프의 작성이 가능하다.
- feed_dict에 의해 나중에 값을 정의할 수 있다.
- 배열, matrix, 몇몇의 숫자 등의 다양한 형태의 값을 가질 수 있다.
- None은 임의의 행의 데이터를 가르킨다.

In [9]:

```
T = tf.placeholder(tf.float32)
print(T)
```

```
Tensor("Placeholder:0", dtype=float32)
```

In [10]:

```
X = tf.placeholder(tf.float32, name='X')
Y = tf.placeholder(tf.float32, name='Y')

print(X)
print(Y)
```

```
Tensor("X:0", dtype=float32)
Tensor("Y:0", dtype=float32)
```

2-4 선형관계 수식 작성

In [11]:

```
# 선형관계의 수식을 작성.
# W : 가중치(Weight), b : 편향(bias)
hypothesis = W * X + b
```

In [12]:

```
# hypothesis = W * X + b
```

2-5 손실함수(loss function)

- 우리는 나중에 학습시에 Loss를 최소화하는 W와 b의 값을 구하게 된다.
- 데이터에 대한 손실값을 계산하는 함수
- 손실값이란 실제값과 모델이 예측한 값이 얼마나 차이가 나는가를 나타내는 값.

- 손실값이 적을 수록 모델이 주어진 X값에 대한 Y값을 정확하게 예측할 수 있다라는 의미
- 손실을 전체 데이터에 대해 구한 경우 이를 비용(cost)이라 한다.

In [15]:

```
display(Image(filename='../img/TF_Regression02.png'))
```

$$\text{Cost}= \frac{1}{m}\sum_{i=1}^{m}\left(H\left(x^{(i)}\right) - y^{(i)}\right)^2$$

식을 만들기

In [16]:

```
# hypothesis(예측) - Y(실제)
# tf.square(예측과실제의차이) -> 제곱
# tf.reduce_mean(a) -> a의 평균
cost = tf.reduce_mean(tf.square(hypothesis - Y))
cost
```

Out[16]:

```
<tf.Tensor 'Mean:0' shape=() dtype=float32>
```

2-6 최적화 함수(경사하강법)

- **경사하강법** : 함수의 기울기를 구하고, 기울기가 낮은 쪽으로 계속 이동시키면서 최적의 값을 찾아 나간다. (즉 손실값을 낮춰가며, 계속 최적의 값을 찾아간다.)
- 경사하강법(gradient descent)는 최적화 방법 중 가장 기본적인 알고리즘이다.
- 최적화 함수란 가중치(w)와 편향(b)을 변경해 가면서 손실값을 최소화시키는 가장 최적화된 가중치와 편향 값을 찾아주는 함수.
- learning_rate는 학습을 얼마나 급하게 할 것인가를 설정하는 값

In [17]:

```
optimizer = tf.train.GradientDescentOptimizer(learning_rate=0.01)
train_op = optimizer.minimize(cost)
train_op
```

Out[17]:

```
<tf.Operation 'GradientDescent' type=NoOp>
```

- 학습을 진행하는 과정 중에 영향을 주는 변수를 **하이퍼파라미터(hyperparameter)**라 한다. 이에 따라 학습 속도와 신경망 성능이 달라질 수 있다

with를 이용하여 세션 블록(세션영역)을 생성

- 출력 순서
- step : 단계
- cost_val : cost 비용
- sess.run(W) : 가중치 값
- sess.run(b) : 편향 값

In [19]:

```
with tf.Session() as sess:
  sess.run(tf.global_variables_initializer())

  for step in range(100):
    _, cost_val = sess.run([train_op, cost], feed_dict={X:x_data, Y:y_data})
    print(step, "Cost = %-10.5f" % cost_val, end=" ")
    print("W = %10.6f" % sess.run(W), end=" ")
    print("B = %10.6f " % sess.run(b), end="₩n")
```

```
0 Cost = 987.66052  W =   2.406130 B =   1.311109
1 Cost = 576.31610  W =   3.998115 B =   1.740519
2 Cost = 336.59995  W =   5.214098 B =   2.065822
3 Cost = 196.90007  W =   6.143047 B =   2.311660
4 Cost = 115.48491  W =   6.852877 B =   2.496844
5 Cost = 68.03518   W =   7.395433 B =   2.635734
6 Cost = 40.37886   W =   7.810294 B =   2.739293
7 Cost = 24.25718   W =   8.127672 B =   2.815890
8 Cost = 14.85735   W =   8.370631 B =   2.871912
9 Cost = 9.37473    W =   8.556778 B =   2.912236
10 Cost = 6.17489    W =   8.699553 B =   2.940584
11 Cost = 4.30538    W =   8.809216 B =   2.959800
12 Cost = 3.21116    W =   8.893600 B =   2.972051
13 Cost = 2.56875    W =   8.958685 B =   2.978994
14 Cost = 2.18969    W =   9.009034 B =   2.981893
15 Cost = 1.96411    W =   9.048133 B =   2.981713
16 Cost = 1.82801    W =   9.078641 B =   2.979190
17 Cost = 1.74408    W =   9.102589 B =   2.974888
18 Cost = 1.69059    W =   9.121526 B =   2.969235
19 Cost = 1.65487    W =   9.136636 B =   2.962559
20 Cost = 1.62953    W =   9.148823 B =   2.955109
21 Cost = 1.61027    W =   9.158775 B =   2.947078
22 Cost = 1.59459    W =   9.167020 B =   2.938610
23 Cost = 1.58102    W =   9.173959 B =   2.929816
24 Cost = 1.56871    W =   9.179899 B =   2.920782
25 Cost = 1.55717    W =   9.185075 B =   2.911573
26 Cost = 1.54611    W =   9.189664 B =   2.902237
27 Cost = 1.53535    W =   9.193804 B =   2.892812
28 Cost = 1.52479    W =   9.197598 B =   2.883327
29 Cost = 1.51439    W =   9.201127 B =   2.873805
30 Cost = 1.50410    W =   9.204451 B =   2.864261
31 Cost = 1.49391    W =   9.207616 B =   2.854709
32 Cost = 1.48381    W =   9.210658 B =   2.845158
33 Cost = 1.47378    W =   9.213604 B =   2.835615
34 Cost = 1.46382    W =   9.216475 B =   2.826087
35 Cost = 1.45393    W =   9.219285 B =   2.816576
36 Cost = 1.44412    W =   9.222048 B =   2.807088
37 Cost = 1.43437    W =   9.224772 B =   2.797623
38 Cost = 1.42468    W =   9.227465 B =   2.788185
39 Cost = 1.41507    W =   9.230131 B =   2.778773
40 Cost = 1.40551    W =   9.232776 B =   2.769390
41 Cost = 1.39602    W =   9.235401 B =   2.760035
42 Cost = 1.38660    W =   9.238010 B =   2.750710
43 Cost = 1.37724    W =   9.240605 B =   2.741416
44 Cost = 1.36794    W =   9.243187 B =   2.732151
45 Cost = 1.35871    W =   9.245757 B =   2.722917
46 Cost = 1.34954    W =   9.248316 B =   2.713713
47 Cost = 1.34043    W =   9.250863 B =   2.704540
48 Cost = 1.33138    W =   9.253401 B =   2.695397
49 Cost = 1.32239    W =   9.255929 B =   2.686285
```

```
50 Cost = 1.31346    W =   9.258448 B =   2.677204
51 Cost = 1.30460    W =   9.260957 B =   2.668153
52 Cost = 1.29579    W =   9.263457 B =   2.659133
53 Cost = 1.28704    W =   9.265948 B =   2.650143
54 Cost = 1.27836    W =   9.268431 B =   2.641183
55 Cost = 1.26973    W =   9.270905 B =   2.632253
56 Cost = 1.26116    W =   9.273371 B =   2.623354
57 Cost = 1.25264    W =   9.275828 B =   2.614485
58 Cost = 1.24419    W =   9.278277 B =   2.605645
59 Cost = 1.23579    W =   9.280718 B =   2.596836
60 Cost = 1.22745    W =   9.283150 B =   2.588056
61 Cost = 1.21916    W =   9.285573 B =   2.579306
62 Cost = 1.21093    W =   9.287989 B =   2.570585
63 Cost = 1.20275    W =   9.290396 B =   2.561894
64 Cost = 1.19464    W =   9.292795 B =   2.553233
65 Cost = 1.18657    W =   9.295186 B =   2.544600
66 Cost = 1.17856    W =   9.297569 B =   2.535997
67 Cost = 1.17061    W =   9.299944 B =   2.527423
68 Cost = 1.16270    W =   9.302311 B =   2.518878
69 Cost = 1.15486    W =   9.304669 B =   2.510362
70 Cost = 1.14706    W =   9.307020 B =   2.501874
71 Cost = 1.13932    W =   9.309363 B =   2.493416
72 Cost = 1.13162    W =   9.311699 B =   2.484986
73 Cost = 1.12399    W =   9.314026 B =   2.476584
74 Cost = 1.11640    W =   9.316345 B =   2.468211
75 Cost = 1.10886    W =   9.318657 B =   2.459866
76 Cost = 1.10138    W =   9.320960 B =   2.451549
77 Cost = 1.09394    W =   9.323256 B =   2.443260
78 Cost = 1.08656    W =   9.325543 B =   2.435000
79 Cost = 1.07922    W =   9.327824 B =   2.426767
80 Cost = 1.07194    W =   9.330096 B =   2.418563
81 Cost = 1.06470    W =   9.332361 B =   2.410386
82 Cost = 1.05751    W =   9.334619 B =   2.402236
83 Cost = 1.05038    W =   9.336868 B =   2.394114
84 Cost = 1.04328    W =   9.339110 B =   2.386020
85 Cost = 1.03624    W =   9.341345 B =   2.377953
86 Cost = 1.02925    W =   9.343572 B =   2.369913
87 Cost = 1.02230    W =   9.345791 B =   2.361901
88 Cost = 1.01540    W =   9.348002 B =   2.353915
89 Cost = 1.00854    W =   9.350207 B =   2.345957
90 Cost = 1.00174    W =   9.352405 B =   2.338025
91 Cost = 0.99497    W =   9.354594 B =   2.330121
92 Cost = 0.98826    W =   9.356776 B =   2.322242
93 Cost = 0.98159    W =   9.358951 B =   2.314391
94 Cost = 0.97496    W =   9.361118 B =   2.306566
95 Cost = 0.96838    W =   9.363278 B =   2.298768
96 Cost = 0.96184    W =   9.365431 B =   2.290996
97 Cost = 0.95535    W =   9.367577 B =   2.283250
98 Cost = 0.94890    W =   9.369715 B =   2.275531
99 Cost = 0.94249    W =   9.371845 B =   2.267837
```

생각해 보기

- 만약 for문을 계속 반복시켜가면 W의 값은 어떤 값에 가까워질까?

2-7 학습 후, 결과값 확인하기

In [13]:

```
with tf.Session() as sess:
  sess.run(tf.global_variables_initializer())

  for step in range(1001):
    _, cost_val = sess.run([train_op, cost], feed_dict={X:x_data, Y:y_data})
    if step%10==0:
      print(step, cost_val, sess.run(W), sess.run(b))

  print()
  print("최종 학습된 결과로 예측해 보기")
  print("Y = {Weight} * X + {Bias} ".format(Weight=sess.run(W), Bias=sess.run(b)))
  print("X:5, Y:", sess.run(hypothesis, feed_dict={X:5}))
  print("X:2.5, Y:", sess.run(hypothesis, feed_dict={X:2.5}))

```

```
0 1086.6752 [2.071835] [1.2386663]
10 6.642415 [8.672422] [2.95255]
20 1.6505979 [9.142491] [2.9721873]
30 1.5219158 [9.199667] [2.8811414]
40 1.4221544 [9.228242] [2.785733]
50 1.3290131 [9.25407] [2.6930044]
60 1.2419746 [9.278919] [2.60333]
70 1.1606374 [9.302931] [2.5166397]
80 1.0846274 [9.326143] [2.4328358]
90 1.0135926 [9.348583] [2.3518229]
100 0.94721144 [9.3702755] [2.273507]
110 0.8851782 [9.391245] [2.1978]
120 0.8272082 [9.411516] [2.124614]
130 0.773033 [9.431112] [2.0538647]
140 0.722408 [9.450056] [1.9854717]
150 0.6750964 [9.4683695] [1.9193556]
160 0.63088334 [9.486073] [1.8554412]
170 0.58956724 [9.503185] [1.7936556]
180 0.5509545 [9.51973] [1.7339272]
190 0.51487255 [9.535723] [1.6761878]
```